

Physical AI 위험 분류체계 독립 전문가 설문 계획서

Protocol for Independent Expert Annotation of the Physical AI Risk Taxonomy

Version 1.0 | 2026-07-10

1 연구 목적 / Study objective

본 조사의 주목적은 각 L4 카드에 기존 L3와 유사 대안 L3를 쌍으로 제시하고 독립 전문가가 어느 후보를 더 적합하다고 판단하는지 검증하는 것이다. 카드-L3 연결의 판별 타당성을 평가하며, 24개 위험군이 유일하거나 최적이라는 점을 검증하지 않는다.

The primary objective is to test whether independent experts prefer the canonical L3 over a closely matched alternative for each L4 card. This evaluates discriminant validity of the card-family links, not uniqueness or optimality of the taxonomy.

2 연구 설계 / Study design

- L4 카드 182개, L3 위험군 24개, 독립 전문가 9명 이상 모집
- 전체 카드의 최소 3회 평가를 위해 최소 19개 완주 응답 목표
- A01-A19 균형 블록, 응답자당 정확히 30개 강제선택 쌍대비교
- 총 570건의 계획 판단; 카드당 3회 또는 4회 평가
- L3 기준 층화 균형 불완전 블록 설계
- 기존 label, 임베딩 결과, 유사도, 군집 ID 및 다른 평가자의 응답에 대한 맹검
- 기존 L3와 같은 L2의 유사 대안 L3를 사전 규칙으로 매칭
- 1차 평가변수: 기존 L3 선택률과 card-level bootstrap 95% CI

3 전문가 선정 / Expert eligibility

3.1 포함 기준 / Inclusion criteria

관련 학위, 관련 학위과정 1년 이상, 산업·공공·표준화 분야 경력 1년 이상, 또는 Physical AI·로봇 안전·자율시스템 위험평가 경험 중 하나 이상을 요구한다.

Eligible experts have a relevant degree, at least one year in a relevant degree programme, at least one year of relevant professional experience in industry, the public sector, or standardization, or substantive experience in Physical AI or robot-safety assessment.

3.2 제외 기준 / Exclusion criteria

공동저자, L3/L4 개발 참여자, 기존 label 열람자 및 독립성을 훼손하는 이해상충 보유자는 제외한다.

4 수집할 배경 정보 / Background variables

설문 문항은 이름, 이메일, 정확한 연령, 소속기관을 요구하지 않는다. 익명 평가자 코드, 연령대, 성별, 전문영역, 경력 구간, 위험평가 경험, 표준·규제 경험 및 독립성을 범주형으로 수집한다. 연

령대와 성별에는 응답하지 않음 선택지를 제공한다.

The questionnaire does not request names, email addresses, exact age, or institutional affiliation. Anonymous respondent code, age band, gender, expertise, experience band, risk-assessment experience, standards or regulatory experience, and independence are collected categorically. Age band and gender include a prefer-not-to-say option.

5 설문 절차 / Survey procedure

1. 연구 안내, 개인정보 처리 안내 및 동의
 2. 적격성 및 배경 정보
 3. 이중언어 L3 codebook과 분류 규칙 검토
 4. 각 L4 카드에 제시된 두 L3 후보 중 더 적합한 하나를 선택
 5. 확신도 및 선택적 의견 기록
 6. 알고리즘 배정과 다른 고확신 응답을 최대 3개까지 재검토한 뒤 구조화된 Markdown 응답 저장
- 후보 A/B의 표시 순서는 무작위화하며 동점 또는 판단 불가 선택지는 제공하지 않는다.

6 카드 표시 및 맹검 / Card presentation and blinding

카드에는 무작위 표시 ID, L4 label·definition 및 두 L3 후보를 표시한다. 어느 후보가 기존 배정인지, L2, 심각도·확률, 참고문헌 수와 계산 결과는 공개하지 않는다. 카드와 후보 순서는 평가자별로 재현 가능하게 무작위화한다.

7 카드별 문항 / Card-level items

1. Pairwise ranking: 후보 A/B 중 L4를 더 잘 설명하는 L3 하나
2. Confidence: 1(매우 낮음)–5(매우 높음)
3. Optional comment

8 자료 보존 / Data retention

응답은 브라우저 localStorage에 자동 임시저장하고 완료 시 구조화된 Markdown으로 변환해 공개 GitHub 응답 저장소에 자동 보존한다. 설문 시작·종료 시각, 총 소요시간과 국가 수준의 접속지역은 응답과 분리된 비공개 GitHub 저장소에 1년간 보존한다. 원본 IP와 더 세부적인 위치·접속·기기 정보는 저장하지 않으며 공개 응답에는 시간 및 국가 정보를 포함하지 않는다. 제한시간은 없다.

9 품질관리 / Quality control

불일치 자체를 이유로 평가자를 제외하지 않는다. 미완료, 독립성 위반, 기술적 손실 또는 사전 정의된 비성실 패턴만 제외 사유로 검토한다. 응답에는 설문 버전, 데이터 스냅샷 해시, 배정 버전과 익명 평가자 코드를 기록한다.

10 분석 계획 / Statistical analysis

10.1 1차 분석 / Primary analysis

분석 단위는 L4 카드이다. 기존 L3 선택률과 카드 단위 bootstrap 5,000회 95% 신뢰구간을 산출하며 선택확률 0.5를 귀무기준으로 사용한다.

10.2 보조 분석 / Secondary analyses

카드별 기존 L3 다수선택률과 완전일치율, family 별 선택률, macro-average와 worst-family 결과, 후보쌍별 선택률, 확신도별 결과 및 margin-인간 선택 관계를 보고한다. 570개 계획 판단을 독립 표본으로 간주하지 않는다. 9-18개 완주 응답은 전체 카드 검증을 위한 중간자료로만 취급한다.

11 사전 의사결정 규칙 / Prespecified interpretation

결과 / Result	해석 및 조치 / Interpretation and action
전체 선택률의 95% CI 하한 > 0.50	매칭 대안보다 기존 연결이 우세하다는 증거
95% CI가 0.50 포함	관별 근거 불충분; 확정적 타당화 주장 금지
Family 선택률 < 60%	family 정의·경계 또는 카드 연결 재검토
3인 중 2인 이상 대안 선택	해당 카드-family 연결을 우선 재검토

기준은 데이터 확인 전에 고정하며 사후 변경하지 않는다.

12 개정 정책 / Revision policy

설문 결과로 L3 정의를 수정한 경우 동일 응답으로 수정된 taxonomy의 성능을 입증하지 않는다. 별도 holdout 또는 신규 전문가로 재검증하거나 미검증 개정안으로 명시한다.

13 산출물 / Deliverables

이중언어 계획서(Markdown, LaTeX, PDF), GitHub Pages 설문, 24개 L3 및 182개 L4 고정 데이터 스냅샷, A01-A19 배정표, Markdown 응답과 데이터 사전을 제공한다.